

# Classificando o impacto humano sobre a floresta amazônica a partir de imagens de satélite



Jonathan J. M. Nunes, Felipe M. Tavares, Lucas David, Rodrigo A. M. Franco

# Notícias recentes (2019~2020)

- Aumento de 61% de aumento de pontos de queimada no ano passado em comparação com o ano anterior
- Nos primeiros sete meses de 2020 uma área equivalente a 8 vezes a cidade de Londres foi queimada na floresta amazônica
- Impunidade aos criminosos e intimidação de defensores do meio ambiente
- Expansão da agropecuária e venda ilegal de madeiras



<https://www.bbc.com/news/world-latin-america-53893161>

<https://www.theguardian.com/environment/2020/oct/01/brazil-amazon-rainforest-worst-fires-in-decade>

<https://www.bbc.com/news/world-latin-america-55130304>

<https://www.hrw.org/report/2019/09/17/rainforest-mafias/how-violence-and-impunity-fuel-deforestation-brazils-amazon>

# A importância da floresta Amazônica

- Um dos maiores ecossistemas do mundo
- Grande biodiversidade
- Ciclo de carbono
- Reserva de água doce
- Controle climático
- Potencial biotecnologia



# O problema

- Exploração ilegal de madeira
- Expansão da Agropecuária
- Carbono na atmosfera
- Aquecimento global



# Metas de desenvolvimento sustentável

- Definidos em 2015 por 195 nações e acordados com a Organização das Nações Unidas.
- Meta de atingir objetivos até 2030



# Competição no Kaggle

- “Planet: Understanding the Amazon from Space”  
<https://www.kaggle.com/c/planet-understanding-the-amazon-from-space/overview>
- Impulsionar monitoramento autônomo
- Solução para identificar diversos tipos de intervenção humana a partir de imagens aéreas
- Amostras Multi-label
- Conjunto de teste altamente desbalanceado

# Pré-processamento

- Utilizadas imagens RGB
- Imagens JPEG convertidas para formato TF-Records

# Baseline

- Rede Neural *EfficientNet-B3* como modelo pré-treinado
- Camada densa igual ao número de classes do problema
- *Classification head* treinado inicialmente por até 80 épocas, camadas congeladas
- Novo treinamento com pesos descongelados por até mais 80 épocas, chamado de *fine tuning*



# Data Balance

- Divisão das amostras entre dominantes e dominados
- Labels *agriculture*, *clear* e *primary* como dominantes e as demais como dominadas
- Subdivisão das dominantes com máximo de uma label
- Subdivisão das dominadas por label
- Amostragem a partir destes subconjuntos

# Experimento: Data Augmentation

- Usado para aumento artificial dos dados e melhorar a generalização do algoritmo
- Aplicado operações de transformação de imagens nas amostras
- *Auto Augmentation*, utilizando políticas pré-treinadas para escolher melhores transformações

# Otimizadores

- Treinamento em dois estágios
- Peso das camadas do *backbone* são congelados e a camada de classificação treinada
- 60% das camadas superiores do *backbone* descongeladas e treinadas novamente com *learning rate* reduzido

# Experimento: Focal Loss

Resolução do problema de treinamento de problemas de classificação em base de dados desbalanceados.

diminuir o peso de classes bem representadas e focar o treinamento nas classes difíceis.

$$FL(p_t) = - \alpha (1 - p_t)^\gamma \log(p_t)$$

pt: Probabilidade ground truth

$\alpha$ : Fator de balanceamento

$\gamma$ : Fator de modulação

- [https://www.tensorflow.org/addons/api\\_docs/python/tfa/losses/SigmoidFocalCrossEntropy](https://www.tensorflow.org/addons/api_docs/python/tfa/losses/SigmoidFocalCrossEntropy)
- <https://paperswithcode.com/method/focal-loss>

# Spatial Pyramid Pooling

- Rede *EfficientNet-B3* usada como *backbone*
- *Spatial Pyramid Pooling* é utilizado para extrair sinais de *features*
- Sinal é transformado em um vetor de *features* concatenados em um vetor descritor da amostra

# Experimento: Model Averaging

- Utilizado o método *Stochastic Weight Averaging* (SWA)
- Intuito de maior generalização para predição de dados não vistos
- Experimentos ambos iniciando na primeira época e salvando pesos a cada 10 épocas:
  - SWA apenas durante a etapa de *fine tuning*
  - SWA durante etapa de *classification head* até a etapa de *fine tuning*




Figure 1: Illustrations of SWA and SGD with a Preactivation ResNet-164 on CIFAR-100<sup>1</sup>. **Left:** test error surface for three FGE samples and the corresponding SWA solution (averaging in weight space). **Middle and Right:** test error and train loss surfaces showing the weights proposed by SGD (at convergence) and SWA, starting from the same initialization of SGD after 125 training epochs.

# Tabela de resultados finais no conjunto de validação e nos conjuntos de teste

Label	EB3 ( <i>baseline</i> )	EB3-B	EB3-SPP	EB3-AdamW	EB3-AA-IN-8	EB3-FL	EB3-SWA
agriculture	<b>84.69%</b>	73.56%	83.21%	83.86%	83.39%	61.55%	84.12%
artisanal_mine	80.87%	<b>90.17%</b>	83.49%	77.15%	74.60%	63.79%	80.36%
bare_ground	12.52%	15.74%	<b>24.16%</b>	11.09%	7.40%	0.00%	12.52%
blooming	0.00%	<b>59.03%</b>	0.00%	0.00%	0.00%	0.00%	0.00%
blow_down	0.00%	<b>35.26%</b>	0.00%	0.00%	0.00%	0.00%	0.00%
clear	96.87%	96.50%	96.63%	<b>97.20%</b>	97.14%	95.62%	96.84%
cloudy	85.23%	<b>88.91%</b>	86.41%	83.31%	80.16%	78.91%	84.60%
conventional_mine	0.00%	<b>76.09%</b>	21.05%	0.00%	0.00%	0.00%	0.00%
cultivation	48.45%	52.67%	51.41%	41.75%	<b>57.93%</b>	12.64%	46.72%
habitation	63.12%	63.86%	60.91%	60.06%	<b>66.69%</b>	20.50%	63.35%
haze	66.14%	<b>66.16%</b>	65.27%	62.90%	65.13%	50.29%	<b>66.48%</b>
partly_cloudy	<b>91.62%</b>	89.78%	90.70%	89.52%	90.20%	83.97%	<b>91.80%</b>
primary	<b>98.56%</b>	98.48%	98.23%	98.54%	<b>98.82%</b>	97.70%	98.69%
road	82.99%	81.35%	83.74%	82.84%	<b>86.02%</b>	63.72%	82.79%
selective_logging	3.70%	<b>38.72%</b>	18.39%	0.00%	0.00%	0.00%	3.69%
slash_burn	0.00%	<b>17.72%</b>	0.00%	0.00%	0.00%	0.00%	0.00%
water	<b>76.44%</b>	73.79%	76.12%	71.90%	71.60%	55.02%	<b>77.13%</b>
Valid Avg. macro	52.42%	<b>65.75%</b>	55.28%	50.60%	51.71%	40.22%	52.30%
Valid Avg. weighted	88.14%	80.39%	87.98%	87.20%	<b>88.26%</b>	78.55%	88.09%
Test Public	90.06%	88.05%	90.06%	89.41%	89.98%	81.09%	<b>90.14%</b>
Test Private	89.78%	87.80%	89.83%	89.22%	89.65%	80.61%	<b>89.90%</b>

# Conclusão

*Planet: Understanding Amazon  
from Space*

Foram aplicadas diversas técnicas para solucionar o desafio *Planet: Understanding Amazon from Space*, o experimento usando a técnica SWA apresentou os melhores resultados.

---



# Obrigado!

